

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN 2

Data Fitting và Phương Pháp OLS

Môn học: Toán Ứng Dụng và Thống Kê
Lớp: 24CTT3

Nhóm 12 (CQ2024-3)

Đinh Đức Hiếu
Liên Trung Hiếu
Trương Đình Nhật Huy
Nguyễn Ngọc Quang
Đặng Quang Tiến

24120002
24120049
24120064
24120127
24120149

Giảng viên hướng dẫn

ThS. Võ Nam Thực Đoan
ThS. Lê Nhựt Nam

Thành phố Hồ Chí Minh, ngày 29 tháng 5 năm 2026

Mục lục

1 Phân công công việc và đánh giá	2
2 Lý thuyết Data Fitting và Minh họa	3
2.1 Data Generation Model	3
2.2 Phương pháp Ordinary Least Squares (OLS)	3
2.3 Đánh giá Mô hình & Ma trận Hat	3
2.4 Các vấn đề nâng cao trong Data Fitting	3
3 Ứng dụng Data Fitting vào Dữ liệu thực tế	5
3.1 Thông tin Bộ dữ liệu	5
3.2 Tiền xử lý Dữ liệu	5
3.3 So sánh Mô hình	5
3.4 Tầm quan trọng của các Đặc trưng	6
3.5 Tác động của Regularization	7
3.6 Kiểm định giả định Gauss-Markov & Bất bệnh mô hình	8
4 Kết luận	9
4.1 Tóm tắt kết quả	9
4.2 Bài học rút ra	9
4.3 Hướng mở rộng	9
5 Tài liệu tham khảo	10
6 Phụ lục	11
6.1 Bảng kiểm định Đa cộng tuyến (VIF)	11
6.2 Chứng minh Toán học Mô hình Ridge Regression	12

1 | Phân công công việc và đánh giá

Bảng 1 : Phân công công việc và đánh giá mức độ đóng góp của các thành viên

STT	MSSV	Họ và tên	Vai trò	Nhiệm vụ	Đánh giá
1	24120002	Đinh Đức Hiếu	Thành viên	Phần 1: Xây dựng thuật toán cốt lõi cho OLS, Ridge, VIF	100%
2	24120049	Liên Trung Hiếu	Thành viên	Phần 2 (ML Modeler): Huấn luyện, tối ưu siêu tham số và so sánh các mô hình	100%
3	24120064	Trương Đình Nhật Huy	Thành viên	Phần 2 (Data Engineer): Làm sạch dữ liệu, EDA và xây dựng Pipeline tiền xử lý	100%
4	24120127	Nguyễn Ngọc Quang	Nhóm trưởng	Quản lý nhóm và Phần 1: Kiểm chứng, phân tích thống kê phương pháp OLS	100%
5	24120149	Đặng Quang Tiến	Thành viên	Phần 2 (Report Analyst): Phân tích chẩn đoán phần dư, trực quan hóa và tổng hợp báo cáo	100%

2 | Lý thuyết Data Fitting và Minh họa

2.1 Data Generation Model

Mô hình dữ liệu giả lập được tạo dựa trên phương trình hồi quy tuyến tính:

$$y = X\beta_{\text{true}} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I) \quad (1)$$

Trong đó $X \in \mathbb{R}^{50 \times 4}$ là ma trận thiết kế (với cột đầu tiên chứa toàn số 1 đại diện cho hệ số chặn intercept), $\beta_{\text{true}} \in \mathbb{R}^4$, và độ lệch chuẩn của nhiễu là $\sigma = 1.5$. Mục đích của việc giả lập này là để chứng minh rằng thuật toán OLS tự cài đặt tạo ra kết quả chính xác tuyệt đối so với các thư viện chuẩn.

2.2 Phương pháp Ordinary Least Squares (OLS)

Nghiệm OLS $\hat{\beta}$ được định nghĩa là giá trị làm cực tiểu hóa tổng bình phương phần dư (RSS). Bằng cách giải hệ phương trình chuẩn:

$$X^T X \hat{\beta} = X^T y \quad (2)$$

Khi $X^T X$ khả nghịch, nghiệm OLS có dạng đóng:

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (3)$$

Thử nghiệm trên dữ liệu giả lập cho thấy, kết quả $\hat{\beta}$ tính bằng code thủ công hoàn toàn khớp với `scikit-learn` và `statsmodels` (sai số ở mức 10^{-15} , do giới hạn làm tròn số của máy tính).

2.3 Đánh giá Mô hình & Ma trận Hat

Hệ số xác định R^2 được tính bằng:

$$R^2 = 1 - \frac{RSS}{TSS} \quad (4)$$

Trên tập dữ liệu giả lập, mô hình OLS giải thích được 94.39% phương sai của y ($R^2 = 0.943864$).

Ma trận chiếu:

$$H = X(X^T X)^{-1} X^T \quad (5)$$

Kiểm tra tính chất của H cho thấy dấu vết $\text{tr}(H) = 4$, đúng bằng số lượng tham số $p + 1$. Tính lũy đẳng $H^2 = H$ cũng được thỏa mãn với sai số 1.25×10^{-16} .

2.4 Các vấn đề nâng cao trong Data Fitting

Đa cộng tuyến: Các giá trị VIF của dữ liệu giả lập đều xấp xỉ 1.0 (ví dụ x_1 : 1.0798), chứng tỏ các biến độc lập không bị đa cộng tuyến.

Bảng suy diễn hệ số: Mô hình ước lượng được phương sai sai số $\hat{\sigma}^2 = 1.922732$. Từ đó tính toán được các sai số chuẩn (Standard Errors), t -statistics và p -values. Tất cả các hệ số đều có ý nghĩa thống kê ($p < 0.05$).

Tóm lại, toàn bộ các hàm tự cài đặt như `ols_fit`, `hat_matrix`, `model_metrics`, `coef_inference` và vif đều vượt qua các bài kiểm thử toán học, sẵn sàng để ứng dụng vào dữ liệu thực tế ở Phần 2.

3 | Ứng dụng Data Fitting vào Dữ liệu thực tế

3.1 Thông tin Bộ dữ liệu

Bộ dữ liệu được nhóm sử dụng là Melbourne Housing (`melb_data.csv`) thu thập thông tin về thị trường bất động sản tại Melbourne, Úc với mục tiêu dự đoán giá nhà (Price).

- Kích thước gốc: 13.580 quan trắc (dòng) và 21 đặc trưng (cột).
- Tính chất: Là bộ dữ liệu thực tế, chứa nhiều dữ liệu bị khuyết và các biến phân loại phức tạp. Dữ liệu này thỏa mãn hoàn toàn các tiêu chí chọn lựa khắt khe của Đồ án 2 (Kích thước lớn, biến mục tiêu liên tục, có missing values).

3.2 Tiền xử lý Dữ liệu


Để mô hình có thể học được chính xác, dữ liệu thô đã được xử lý tự động thông qua một `DataPipeline` chặt chẽ:

- Xử lý dữ liệu không hợp lệ & Khuyết thiếu: Các giá trị phi logic (ví dụ `BuildingArea <= 0` hay `YearBuilt < 1800`) được ép về dạng missing. Sau đó, nhóm áp dụng phương pháp K-Nearest Neighbors (`KNNImputer`) để điền khuyết cho các biến định lượng. Việc điền khuyết (fit) chỉ diễn ra trên tập huấn luyện nhằm tránh rò rỉ dữ liệu.
- Trích xuất đặc trưng: Tạo thêm các biến có ý nghĩa cao như Tuổi của căn nhà (`Age = 2026 - YearBuilt`) hay Tỷ lệ xây dựng (`BuildingCoverage = BuildingArea / Landsize`).
- Mã hóa và Chuẩn hóa: Áp dụng One-hot encoding cho các biến phân loại (`Type`, `Regionname`). Tất cả các đặc trưng định lượng cuối cùng đều được đưa về cùng một thang đo bằng Z-score Standardization.
- Lược bỏ biến: Các biến có tính định danh quá cao (như `Address`, `SellerG`) hoặc gây trùng lặp thông tin (như `Postcode`, `Bedroom2`) đều bị loại bỏ nhằm giúp ma trận thiết kế gọn gàng, hạn chế hiện tượng đa cộng tuyến.

3.3 So sánh Mô hình

Dựa trên kết quả đo lường từ tập kiểm thử, mô hình `OLS_selected` (OLS với các biến đã qua chọn lọc) đạt hiệu năng tốt nhất với RMSE xấp xỉ 419,817 và $R^2 \approx 0.575$. Mặc dù mô hình Ridge Regression (với siêu tham số $\lambda = 1000$) có cơ chế phạt giúp giảm thiểu over-fitting, nhưng trong trường hợp này, khi hiện tượng đa cộng tuyến đã được nhóm chủ động xử lý bằng cách loại bỏ biến (chẳng hạn `Bedroom2`, `YearBuilt`), mô hình OLS cơ bản vẫn duy trì được độ chính xác và tính dễ diễn giải mà không bị lép vế trước Ridge.

3.4 Tầm quan trọng của các Đặc trưng




Hình 1 : Biểu đồ Tầm quan trọng của các Đặc trưng (OLS_selected)

Nhìn vào biểu đồ trọng số (Coefficients), ta có thể rút ra những hiểu biết sâu sắc (insights) về thị trường bất động sản Melbourne:

- Vị trí địa lý là yếu tố then chốt: Biến *Distance* (khoảng cách tới trung tâm thành phố) có trọng số âm lớn nhất. Điều này hoàn toàn phù hợp với thực tế: nhà càng xa trung tâm thì giá càng giảm mạnh.
- Không gian sống quyết định giá trị gia tăng: Các biến liên quan đến quy mô như *Rooms* (số phòng) và *BuildingArea* (diện tích xây dựng) có trọng số dương rất cao, kéo giá trị của bất động sản lên đáng kể.
- Các yếu tố này kết hợp lại cho thấy người mua nhà tại Melbourne sẵn sàng trả giá rất cao cho sự tiện lợi (gần trung tâm) và không gian rộng rãi.


3.5 Tác động của Regularization



Hình 2 : Đường cong Lỗi K-Fold CV theo siêu tham số λ

Thông qua phương pháp K-Fold Cross-Validation ($k = 5$), mô hình Ridge đã khảo sát và tìm được siêu tham số tối ưu $\lambda = 1000$. Biểu đồ cho thấy khi λ tăng, lỗi RMSE trên tập validation ban đầu có xu hướng đi ngang rồi tăng vọt nếu λ quá lớn (bóp nghẹt quá mức các hệ số). Dù vậy, hiệu năng của Ridge vẫn không vượt qua được OLS, chứng tỏ ma trận dữ liệu sau khi được chọn lọc biến đã đủ vững chãi (well-conditioned).

3.6 Kiểm định giả định Gauss-Markov & Bất bệnh mô hình



Hình 3 : 4 Biểu đồ chẩn đoán phần dư cho mô hình OLS_selected

Dựa vào các biểu đồ chẩn đoán, ta có thể đánh giá một cách trung thực về giới hạn của mô hình OLS:

- Hiện tượng phương sai thay đổi: Biểu đồ *Residuals vs Fitted* có dạng hình phễu mở rộng dần sang phải. Điều này phản ánh sai số dự báo của mô hình rất thấp đối với các căn nhà giá rẻ, nhưng lại sai số cực lớn đối với các bất động sản đắt tiền. Nguyên nhân là do hành vi định giá của phân khúc “siêu giàu” chịu tác động bởi các yếu tố cảm xúc, kiến trúc độc bản hoặc phong thủy – những biến ẩn không có trong file dữ liệu.
- Phân phối của phần dư: Biểu đồ *Normal Q-Q* cho thấy phần dư bám sát đường chéo ở đoạn giữa nhưng lệch mạnh ở hai đuôi (tails). Điều này vi phạm giả định chuẩn (GM5), cho thấy dữ liệu có chứa nhiều điểm ngoại lai (outliers) hoặc phân đuôi dày (heavy tails).
- Điểm ảnh hưởng (Leverage): Biểu đồ *Residuals vs Leverage* cho thấy một vài điểm dữ liệu có đòn bẩy cao, có thể là những căn biệt thự có diện tích đất cực kỳ lớn làm xoay trục đường hồi quy.

Bài học rút ra: Để khắc phục điểm yếu này trong tương lai, một giải pháp khả thi là thực hiện biến đổi Logarithm cho biến mục tiêu Price để kéo các giá trị siêu lớn về quy mô tuyến tính, giúp mô hình OLS giảm bớt hiện tượng phương sai thay đổi.

4 | Kết luận

4.1 Tóm tắt kết quả

- Mô hình OLS cơ bản sau khi xử lý đa cộng tuyến (OLS_selected) cho kết quả tốt nhất.
- Đã hoàn thành hệ thống code từ đầu ở Phần 1 và ứng dụng thực tế thành công ở Phần 2.

4.2 Bài học rút ra

- Quá trình tiền xử lý dữ liệu (đặc biệt là điền khuyết và loại bỏ biến) có tác động mạnh mẽ hơn cả việc tối ưu siêu tham số của thuật toán.
- Phương pháp trực quan hóa phần dư giúp “bắt bệnh” mô hình một cách khách quan thay vì chỉ nhìn vào chỉ số RMSE.

4.3 Hướng mở rộng

- Thực hiện biến đổi Logarithm cho biến mục tiêu để xử lý phương sai thay đổi.
- Thu thập thêm các đặc trưng mới (về tiện ích xung quanh, chất lượng môi trường) để nâng cao R^2 .

5 | Tài liệu tham khảo

1. Gilbert Strang. *Introduction to Linear Algebra*, 6th ed. Wellesley-Cambridge Press, 2023.
2. Gareth James, Daniela Witten, Trevor Hastie & Robert Tibshirani. *An Introduction to Statistical Learning*, 2nd ed. Springer, 2021.
3. Trevor Hastie, Robert Tibshirani & Jerome Friedman. *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.
4. Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
5. Kevin P. Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, 2022.

6 | Phụ lục

6.1 Bảng kiểm định Đa cộng tuyến (VIF)

Dưới đây là bảng kết quả đo lường chỉ số VIF từ DataPipeline tại Trạm kiểm soát số 2 (Sync Point 2), cung cấp bằng chứng toán học để đưa ra quyết định loại bỏ các cột BuildingArea_per_Room và Bedroom2.

Tên Đặc trưng	Chỉ số Cột	Điểm VIF
Rooms	0	10.50
Distance	1	2.16
Bedroom2	2	8.88
Bathroom	3	1.80
Car	4	1.27
Landsize	5	1.13
BuildingArea	6	36.23
Latitude	7	2.64
Longitude	8	4.02
Propertycount	9	1.16
BuildingArea_missing	10	2.50
YearBuilt_missing	11	2.50
Landsize_zero_or_missing	12	1.70
Age	13	1.34
BuildingArea_per_Room	14	35.93
BuildingCoverage	15	1.01
Type_t	16	1.22
Type_u	17	2.29
Regionname_Eastern Victoria	18	1.24
Regionname_Northern Metropolitan	19	4.84
Regionname_Northern Victoria	20	1.29
Regionname_South-Eastern Metropolitan	21	2.01
Regionname_Southern Metropolitan	22	4.34
Regionname_Western Metropolitan	23	6.65
Regionname_Western Victoria	24	1.39

Việc phát hiện và loại bỏ các biến có VIF > 5.0 (đặc biệt là các cặp tỷ lệ thuận như Tổng diện tích và Diện tích mỗi phòng) đã đóng vai trò sống còn trong việc bảo vệ tính khả nghịch của ma trận $X^T X$.

6.2 Chứng minh Toán học Mô hình Ridge Regression

Ở Phần 1, nhóm đã trình bày nghiệm đúng của Ordinary Least Squares (OLS). Để mở rộng, phần này trình bày chứng minh toán học của phương pháp Ridge (phương pháp được sử dụng ở Phần 2) nhằm giải quyết triệt để tính bất định của ma trận $X^T X$ khi có đa cộng tuyến.

Hàm mục tiêu của Ridge Regression bổ sung thêm thành phần phạt L2 (λ):

$$L(\beta) = (y - X\beta)^T (y - X\beta) + \lambda \beta^T \beta \quad (6)$$

Tiến hành lấy đạo hàm bậc 1 theo vector β và cho bằng vector 0:

$$\frac{\partial L(\beta)}{\partial \beta} = -2X^T(y - X\beta) + 2\lambda\beta = 0 \quad (7)$$

Triển khai và triệt tiêu hằng số 2:

$$X^T(y - X\beta) = \lambda\beta \quad (8)$$

Phân phối ma trận X^T :

$$X^T y - X^T X\beta = \lambda\beta \quad (9)$$

Chuyển về chứa β sang một bên:

$$X^T X\beta + \lambda\beta = X^T y \quad (10)$$

Rút β làm nhân tử chung (với I là ma trận đơn vị cùng cấp):

$$(X^T X + \lambda I)\beta = X^T y \quad (11)$$

Nhân nghịch đảo hai vế, ta thu được nghiệm đúng (closed-form solution) của Ridge:

$$\hat{\beta}_{\text{ridge}} = (X^T X + \lambda I)^{-1} X^T y \quad (12)$$

Ý nghĩa toán học: Ma trận $(X^T X)$ có thể bị suy biến (định thức xấp xỉ 0) nếu có đa cộng tuyến. Việc cộng thêm ma trận đường chéo λI giúp ép tất cả các trị riêng (eigenvalues) của ma trận này lớn hơn 0, đảm bảo nó luôn tồn tại ma trận nghịch đảo. Điều này giải thích tại sao Ridge Regression có khả năng xử lý hiện tượng Over-fitting và đa cộng tuyến cực kỳ mạnh mẽ.